论文编号：202208064722

本科毕业论文（设计）

基于 RAG 与工作流的中原工学院招生咨询系统

Admission Consulting System of Zhongyuan University of Technology Based on RAG and Workflow

学院名称： 人工智能学院

专　　业： 人工智能

班　　级： 人工智能 221

学　　号： 202208064722

学生姓名： 曾令洁

指导教师： 车战斌

2026　年　5　月

诚信承诺书

本人郑重声明：本人所呈交的毕业论文（设计），是在导师的指导下独立进行研究所取得的成果。毕业论文（设计）中凡引用他人已经发表或未发表的成果、数据、观点等，均已明确注明出处。除文中已经注明引用的内容外，不包含任何其他个人或集体已经发表或在网上发表的论文。

论文作者签名：_____ 日期：_____

摘　要

针对高校招生咨询中问题类型复杂、资料来源分散、回答口径要求严格等实际需求，本文以中原工学院招生资料为基础，设计并实现了一套基于检索增强生成（Retrieval-Augmented Generation，RAG）与工作流编排的招生咨询系统。系统采用前后端分离架构，前端基于 Vue 3、TypeScript 与 Vite 构建多会话咨询界面，支持普通对话、RAG 问答、专家模式切换和 SSE 流式响应；后端以 FastAPI 作为统一入口，提供查询改写、问题路由、结构化招生查询、混合检索、答案生成、引用校验、会话记忆、技能调用、健康检查和故障降级等功能。系统知识层同时管理招生章程、报考指南、学院介绍等非结构化文档，以及专业目录、分数线、政策附表等结构化数据，能够支撑政策说明、学费学制、专业代码、选科要求、历年分数线和复合型咨询等典型招生问答场景。

本文重点解决了招生咨询系统中“自然语言问题如何匹配异构资料”“字段型问题如何避免大模型自由发挥”“复杂咨询如何按步骤调用不同能力”以及“证据不足时如何保守回答”等关键问题。为此，系统构建了由 FAISS 稠密检索、BM25 稀疏检索、精确匹配、RRF 融合、重排和质量闸门组成的混合检索链路，并针对字段约束明显的问题引入结构化查询与查询形态自适应路由机制，使学费、专业代码、选科要求和分数线等问题优先进入确定性更强的查询路径。与此同时，系统采用工作流编排组织子问题拆分、工具调用、结果审查和答案汇总，并加入引用校验、冲突裁决、输入输出安全审查、隔离执行器和多级降级机制，从工程层面降低事实幻觉、年份混淆和依赖故障对回答质量的影响。

实验部分从功能测试、招生 RAG 专项评测、检索消融、并发压测和故障注入等方面对系统进行了评价。70 个样本的招生 RAG 专项评测结果显示，系统工具路由准确率达到 100%，平均总分为 0.7443，Recall@5、MRR@5 和 nDCG@5 分别为

0.6976、0.9857 和 0.8078；其中专业目录类样本平均总分达到 0.9799，说明结构化查询链路在字段型问题上具有较高稳定性。检索消融实验中，启用查询形态自适应策略的 feature_on 方案综合评价分为 0.7884，高于默认混合检索基线 feature_off 的 0.6236，也高于 dense_only 和 bm25_only 等单一路径方案，表明面向招生场景进行路由分流和精确检索增强比简单堆叠检索组件更有效。问答质量抽样评测中，关键词覆盖率和引用命中率均为 100%，幻觉率为 0；并发 5、30 和 100 下系统错误率均为 0，RAG 故障注入场景下 8/8 请求均以 degraded 状态返回且未出现 HTTP 5xx，验证了系统的可用性和降级能力。

从开发完成度看，本文系统已完成核心功能的初步开发与本地联调，形成了前端交互、后端网关、知识库索引、结构化数据查询、工作流编排、会话记忆和运维接口等主要模块，并具备通过脚本重复评测和分析结果的能力。当前系统定位为面向毕业设计与业务验证的智能招生咨询原型，尚未作为正式线上招生服务投入生产运营；专家模式的复杂任务规划、检索重排调优、跨实例共享、统一会话存储和部署架构收敛仍需继续完善。总体来看，系统已实现关键业务链路和关键技术功能，验证了“结构化查询 + 混合检索 + 工作流编排 + 可靠性控制”技术路线在高校招生咨询场景中的可行性。

关键词：RAG；工作流编排；招生咨询；混合检索；智能问答系统

ABSTRACT

To address the practical requirements of university enrollment consultation, including diverse question types, scattered information sources, and strict consistency of answers, this thesis designs and implements an admission consulting system for Zhongyuan University of Technology based on Retrieval-Augmented Generation (RAG) and workflow orchestration. The system adopts a front-end and back-end separated architecture. The front end is built with Vue 3, TypeScript, and Vite, supporting multi-session consultation, normal dialogue, RAG-based question answering, expert-mode switching, and streaming responses through Server-Sent Events. The back end uses FastAPI as the unified gateway and provides query rewriting, question routing, structured admission lookup, hybrid retrieval, answer generation, citation validation, session memory, skill invocation, health checking, and fault degradation. At the knowledge layer, the system manages both unstructured documents such as admission regulations, application guides, and college profiles, and structured data such as major catalogs, score lines, and policy tables, thereby supporting typical admission consultation tasks including policy explanation, tuition and schooling duration lookup, major code retrieval, subject requirement inquiry, historical score-line query, and compound consultation.

This work focuses on several key problems: how to match natural-language questions with heterogeneous admission materials, how to prevent large language models from freely generating answers for field-level questions, how to invoke different capabilities step by step for complex consultation, and how to respond conservatively when evidence is insufficient. To solve these problems, the system builds a hybrid retrieval pipeline consisting of FAISS dense retrieval, BM25 sparse retrieval, exact match, reciprocal rank fusion, reranking, and quality gating. For questions with clear field constraints, the system introduces structured

lookup and query-form adaptive routing, so that questions about tuition, major codes, subject requirements, and score lines are directed to more deterministic query paths. In addition, workflow orchestration is used to organize sub-question decomposition, tool invocation, result review, and answer aggregation. Citation validation, conflict resolution, input/output safety checks, isolation execution, and multi-level degradation are also integrated to reduce hallucination, year confusion, and dependency failure in high-caution admission scenarios.

The system is evaluated through functional testing, dedicated enrollment RAG evaluation, retrieval ablation, concurrency stress testing, and fault injection. In the 70-case enrollment RAG evaluation, tool routing accuracy reaches 100%, the average overall score is 0.7443, and Recall@5, MRR@5, and nDCG@5 are 0.6976, 0.9857, and 0.8078 respectively. Major-catalog questions achieve an average overall score of 0.9799, indicating that the structured query path is highly stable for field-level questions. In the retrieval ablation experiment, the query-form adaptive strategy `feature_on` obtains an overall score of 0.7884, outperforming the default hybrid retrieval baseline `feature_off` with 0.6236 as well as single-path schemes such as `dense_only` and `bm25_only`. These results show that routing and exact-retrieval enhancement for the admission domain are more effective than simply stacking retrieval components. In sampled answer-quality evaluation, both keyword coverage and citation hit rate reach 100%, and the hallucination rate is 0. Under concurrency levels of 5, 30, and 100, the system maintains an error rate of 0. In RAG fault injection, all 8 requests return in a `degraded` state without HTTP 5xx, verifying system availability and fallback capability.

In terms of development status, the system has completed initial development and local integration of its core functions. The main modules, including front-end interaction, back-end gateway, knowledge-base indexing, structured data lookup, workflow orchestration, session memory, and operations interfaces, have been implemented, and the project can re-

peatedly run evaluation scripts and analyze results. At present, the system is positioned as an intelligent admission consultation prototype for graduation-design and business-validation purposes, and has not yet been deployed as an official online admission service. Further work is still needed on expert-mode task planning, retrieval reranking, cross-instance sharing, unified session storage, and deployment convergence. Overall, the system has implemented the key business process and technical functions, and verifies the feasibility of combining structured query, hybrid retrieval, workflow orchestration, and reliability control in university enrollment consultation.

Keywords: RAG; Workflow Orchestration; Enrollment Consultation; Hybrid Retrieval; Intelligent Question Answering System

目次

摘要 I
第一章 绪论 1
1.1 研究背景 1
1.2 国内外研究现状 2
1.2.1 检索增强生成研究现状 2
1.2.2 代理式推理与工作流编排研究现状 3
1.2.3 高校垂直问答系统研究现状 3
1.3 研究内容与目标 4
1.4 论文结构 5
第二章 相关技术与理论基础 6
2.1 大语言模型与检索增强生成 6
2.2 混合检索相关技术 6
2.2.1 稠密检索与向量索引 6
2.2.2 稀疏检索与 BM25 7
2.2.3 精确匹配、融合与重排 7
2.3 工作流编排与代理式问答 7
2.4 系统开发相关技术 8
第三章 需求分析与系统总体设计 9
3.1 业务场景分析 9
3.2 功能需求分析 9
3.3 非功能需求分析 10
3.4 系统总体架构设计 11
3.5 数据源与知识组织设计 12
第四章 系统关键模块设计与实现 13
4.1 招生知识库构建 13
4.2 混合检索增强模块设计 13
4.3 结构化招生查询模块设计 14
4.4 专家模式与工作流编排设计 15
4.5 会话记忆与技能机制设计 17
4.6 可靠性与安全控制设计 17
第五章 系统测试与结果分析 19
5.1 测试环境与方案设计 19
5.2 功能测试结果 20

5.3 招生 RAG 专项评测分析 20
5.4 检索消融实验分析 22
5.5 性能与容错测试分析 23
5.6 结果讨论 25
第六章 结论与展望 26
6.1 研究结论 26
6.2 不足与后续工作 26
参考文献 28
附录 30
附录 A 系统主要接口 30
附录 B 主要数据源与脚本 30
致谢 31

1 第一章 绪论

1.1 研究背景

高校招生工作近几年明显呈现出两个变化。其一，咨询入口越来越线上化，问题不再只来自招生现场和热线电话，而是同时分布在官网、公众号、咨询平台和临时活动页面上；其二，咨询内容越来越细碎，除了章程、计划、专业介绍等常规问题，考生和家长还会频繁追问某个省份、某个专业、某个年份的具体字段信息。对招生部门而言，这意味着简单的信息发布已经不够，必须提供更及时、更一致，也更容易被普通用户理解的答复服务。

传统 FAQ 系统在这一场景下有明显短板。它能覆盖高频固定问法，但很难处理自然语言表达差异，更难把分散在章程、学院介绍、专业目录、历年分数线和报到流程中的信息整合起来。纯人工咨询虽然更稳，但响应速度受限，且不同老师对同一问题的表述可能不一致。随着大语言模型在问答领域表现出较强的语言理解和表达能力，利用模型构建招生咨询系统看起来是一条自然的路线，但真落到业务上就会发现，模型“会说”不等于“能说准”。

招生咨询属于高谨慎场景。学费、选科要求、录取批次、报到时间、联系方式这些信息看起来都是小字段，一旦答错，对考生决策的影响却很直接。也正因为如此，招生问答系统的核心目标不能只停留在“回答自然”，还必须满足三条底线：第一，答案尽量来自可核验的学校资料；第二，涉及精确字段时尽量走结构化查询而不是语言猜测；第三，当证据不足时，系统宁可保守也不能装懂。

RAG 技术正是在这种背景下进入高校垂直场景的。它通过在生成前检索外部资料，让模型基于局部证据回答问题，从而缓解知识静态化带来的幻觉问题 [1, 2]。但从项目实现角度看，单纯“向量检索 + 大模型生成”仍然不够，因为招生问题里既有语义问答，也有数值字段、时间敏感信息和多步骤咨询。若系统只会统一走一条

链路，很多该查库的问题反而会被错误地交给生成模型处理。

因此，本文把课题落点放在“RAG 与工作流的结合”上。这里的工作流，不是为了把系统包装得更花哨，而是为了把不同类型的问题分流到合适的能力模块：字段类问题优先走结构化查询，解释类问题走混合检索，复杂问题通过步骤化执行组织记忆、检索、工具与答案整合。在已有项目基础上，本文尝试回答一个更实在的问题：在高校招生这个高谨慎、强时效、资料格式又很杂的场景里，能不能做出一套答得相对稳、证据说得清、出了故障还能保底的智能咨询系统。

1.2 国内外研究现状

1.2.1 检索增强生成研究现状

RAG 已经成为大语言模型应用中最常见的知识增强路线之一。Lewis 等提出的基础框架把外部检索与文本生成结合起来，使模型在回答时不必完全依赖参数记忆，而是能够从外部资料中临时获取证据 [1]。后续研究不断扩大这一路线的边界，Gao 等从索引构建、检索策略、生成控制和评价方法等角度对大模型时代的 RAG 做了系统梳理，指出真正决定效果的往往不是单个模型，而是数据组织、召回策略和证据使用方式 [2]。

在工程实践中，纯向量检索并不能覆盖所有问题。对于金额、专业代码、年份和联系方式这类硬约束字段，BM25 等稀疏检索方法依然有很高价值 [3]；当系统需要同时参考多个召回通道时，RRF 之类的融合方法又能够在不引入复杂学习成本的前提下提升结果稳定性 [4]。Johnson 等提出的 FAISS 为本地向量索引提供了高效实现，使中小规模垂直语料库的相似检索部署门槛大幅降低 [5]。这些研究给本文的技术选择提供了直接依据。

不过，RAG 的难点并不只在“能不能找到资料”，还在“拿到资料以后怎么用”。如果证据排序不稳，或者模型没有按证据作答，系统依然可能在最终答案阶段出错。

也就是说，检索增强并不会自动带来答案忠实性，证据质量控制和答案约束仍然需要在系统层面额外设计。

1.2.2 代理式推理与工作流编排研究现状

近两年，研究关注点逐步从“给模型更多文档”转向“让模型在任务中更主动地决定何时检索、何时推理、何时调用工具”。ReAct 将推理和行动交替组织，使模型能在任务执行中使用外部环境信息修正自身判断 [6]。Search-o1 则进一步把主动检索和长链路推理结合起来，探索在复杂问题中如何根据中间不确定点触发搜索，再把检索结果继续纳入后续推理过程 [7]。相关综述也显示，Agentic RAG 的发展方向已经不再局限于召回优化，而是开始强调任务规划、证据利用、执行轨迹可审计和多轮反馈闭环 [8, 9]。

这些研究对高校招生咨询尤其有启发。招生问题并不是一个固定模版任务，它常常同时包含“信息检索”“字段核对”“流程解释”和“上下文追问”几种需求。把它们都硬塞进单轮问答里，系统表现通常不会太稳定。工作流编排的价值，恰恰在于把任务拆成更适合执行和控制的步骤，让系统在每一步都能决定：接下来是检索、查库、重写问题，还是干脆给出保守说明。

1.2.3 高校垂直问答系统研究现状

高校问答系统并不是新事物，早期很多系统采用规则模板、关键词匹配或 FAQ 检索，能解决一部分固定问题，但很难应对跨文档整合和自然语言追问。随着大模型能力增强，越来越多场景开始尝试基于 LLM 的咨询服务。但对高校业务而言，能否引入大模型只是第一步，更关键的是如何把校内资料真正组织成可追溯的知识底座。

高校招生场景有几个典型特点。第一，资料来源多而杂，既有 Word、PDF、Excel，也有网页、Markdown 和人工整理文本。第二，字段表达不统一，同一个概念可能在不同资料里出现不同写法。第三，时效性强，去年和今年的政策不能混答。第四，部

分问题本质上属于数据库查询，一旦交给生成式模型自由发挥，风险反而更高。现有很多通用问答系统对这类现实细节处理并不充分。

因此，围绕高校招生咨询做系统设计，真正值得研究的不是“大模型能不能回答”，而是如何把结构化与非结构化知识结合起来、如何让系统在复杂问题中按步骤调用不同能力、以及如何用工程化手段尽量降低错误输出。本文的工作正是在这一缺口上展开。

1.3 研究内容与目标

本文研究对象是“基于 RAG 与工作流的中原工学院招生咨询系统”。与单纯做算法验证不同，本文更加关注真实业务资料、真实系统结构和真实评测结果，希望在不夸大能力边界的前提下，给出一套可复现、可解释的实现方案。

结合现有项目代码、文档与评测材料，本文主要完成了以下几项工作：

1. 设计并实现招生知识底座，完成对章程、学院介绍、招生专业详情、录取分数线和问答资料的清洗、解析、切块、索引和结构化入库。
2. 设计混合检索链路，将稠密检索、BM25 检索、精确匹配、RRF 融合、重排和质量闸门串联起来，支撑解释类问题与证据型回答。
3. 设计工作流式问答编排机制，将查询改写、结构化工具、记忆、技能和答案整合组织为可追踪步骤，用于处理复杂咨询任务。
4. 构建前后端完整原型，并基于现有脚本完成功能、检索、问答质量、性能和容错分析。

围绕这些工作，本文希望达成四个目标：第一，在招生资料异构且问题表达自然的条件下，提高系统的字段准确性和证据利用能力；第二，在复杂问题场景中，通过工作流编排提高系统处理过程的清晰度和可控性；第三，在依赖服务异常时仍尽量维持主链路可用；第四，为后续高校垂直问答系统建设提供具有工程可操作性的参考。

1.4 论文结构

全文共分为六章。

1. 第一章为绪论，主要介绍研究背景、国内外研究现状、研究内容与论文结构。
2. 第二章介绍系统设计所依赖的相关技术，包括大语言模型、RAG、混合检索、工作流编排以及系统开发技术基础。
3. 第三章从业务需求出发，对系统总体架构、模块划分和知识组织方式进行分析与设计。
4. 第四章详细说明系统关键模块的实现，包括知识库构建、混合检索、结构化查询、专家模式、记忆与可靠性设计。
5. 第五章结合现有测试和评测报告，对系统的功能效果、检索表现、消融结果、性能瓶颈和容错能力进行分析。
6. 第六章总结全文工作，指出系统当前不足，并给出下一步优化方向。

2 第二章 相关技术与理论基础

2.1 大语言模型与检索增强生成

大语言模型的优势在于语义理解和自然语言生成能力强，尤其适合把来源不同、表达方式不同的资料组织成连贯回答。但对于高校招生这种高风险问答场景，单靠模型参数中“记住的知识”是远远不够的。因为模型训练数据既不一定覆盖学校最新资料，也无法保证在回答时自动区分出哪个年份、哪个来源才是当前有效依据。

RAG 的基本思想，就是在生成前先从外部知识源中检索与问题相关的材料，再把这些材料和问题一起交给模型处理 [1]。相比纯生成方式，它最大的优点是让模型有机会“看见”当前语料库中的真实文本，从而提升回答的事实性和可解释性。Gao 等的综述指出，RAG 系统的效果通常受五类因素影响：数据组织方式、切块粒度、召回策略、证据排序方式以及答案生成约束 [2]。这说明 RAG 并不是一个单点算法，而更像一条完整的工程链路。

在本文的项目场景中，RAG 的价值主要体现在两个方面。第一，招生章程、报考指南、学院介绍等资料都具有较强文本性，适合通过切块与检索方式参与问答。第二，很多问题虽然最终需要自然语言表达，但其答案依据必须来自具体文本片段，例如某条政策说明、某个学院简介或某段报到须知。RAG 使系统能够在给出结论时附带来源，至少在机制上为“有据可查”提供了基础。

2.2 混合检索相关技术

2.2.1 稠密检索与向量索引

稠密检索通过把问题和文档映射到同一向量空间中来计算相似度，优点是能够处理词面差异较大的语义匹配问题。对于“计算机类专业有哪些发展方向”“人工智能学院主要培养什么能力”这类描述型问题，稠密检索通常比纯关键词匹配更稳。项目

中使用 FAISS 作为本地向量索引，其优点是部署简单、检索速度快、适合中小规模垂直知识库 [5]。

2.2.2 稀疏检索与 BM25

虽然向量检索对语义问题很有效，但在金额、年份、专业代码和专有名词等强约束场景中，它并不总是最优。BM25 这类稀疏检索模型对关键词与词频变化更敏感，往往能够在字段定位上提供更直接的支持 [3]。例如用户问“软件工程学费多少”“2025 年河南物理类最低分多少”，这些问题就更适合让稀疏检索参与召回。

2.2.3 精确匹配、融合与重排

招生资料里还有一类问题甚至不适合只靠相似检索处理，例如学院网址、联系电话、专业代码等短字段。对此，项目里额外设计了精确匹配通道，用来对疑似硬字段问题做规则化补强。多路召回结果再通过 RRF 融合到一个统一排序空间中，避免完全依赖单一路径 [4]。之后系统还会调用重排器做二次排序，理论上可以进一步提升候选证据与问题的相关性。

不过，重排并不天然带来收益。后文第五章的消融结果表明，在当前实现与当前数据条件下，查询改写和重排并没有稳定提升评测指标，反而带来额外时延。这也说明，检索系统的每一层设计都必须接受数据验证，不能仅凭理论印象判断效果。

2.3 工作流编排与代理式问答

工作流编排的核心价值，是把一个复杂问题拆成更可控的若干步骤。ReAct 的研究已经表明，当模型能够在推理过程中调用外部行动时，复杂任务的表现会明显不同于“直接一步回答”[6]。在招生咨询场景里，工作流编排同样重要：用户一句“我这个分数能报什么专业，顺便告诉我学费和学院联系方式”，背后往往就包含检索、查库、

筛选和组织表达多个环节。

项目中采用 LangGraph 组织工作流节点，其好处在于流程边界清晰，便于插入查询改写、子问题拆分、结果审查和故障降级等控制逻辑 [11]。这种图式编排与传统链式调用相比，更适合在节点之间做状态传递和重试控制，也更方便后续扩展额外能力。

代理式问答并不意味着系统必须“全自动联网思考”。在本文语境下，它更准确的含义是：系统能够根据问题类型，主动决定调用哪类能力，并把中间过程组织成可追踪的执行步骤。只要这一点做到了，工作流就已经对系统的可解释性和可维护性产生了价值。

2.4 系统开发相关技术

从实现层面看，项目采用的是前后端分离架构。前端使用 Vue 3、TypeScript 和 Vite，重点在于快速构建对话界面、多会话状态和 SSE 消息消费能力；后端使用 FastAPI 提供统一 API 入口，并借助 Pydantic 与 `pydantic-settings` 管理接口契约和运行配置 [10, 11]。

在数据处理方面，项目使用 `python-docx`、`PyPDF2`、`openpyxl` 和 `xlrd` 处理不同格式资料，再通过 MySQL 维护结构化招生表。这样的技术选型没有追求复杂，而是直接围绕业务资料形式展开，符合课程项目中“能稳定落地比堆技术名词更重要”的原则。

3　第三章　需求分析与系统总体设计

3.1　业务场景分析

本系统对应的是中原工学院招生咨询业务，目标用户主要包括考生、家长和招生工作人员。结合现有资料和项目实现，可以把咨询场景概括为三类。

第一类是政策说明类问题，例如“招生章程里对体检有哪些要求”“学校资助政策包括哪些内容”“新生报到需要注意什么”。这类问题通常需要系统从非结构化资料中抽取多个片段，再整合成可读回答。

第二类是字段精确类问题，例如“某专业学费是多少”“某专业代码是什么”“某省某批次最低录取分数线是多少”。这类问题虽然表面上也是自然语言输入，但本质更接近数据库查询，回答正确与否取决于结构化数据是否完整和路由是否准确。

第三类是复合型问题，例如“我的分数能报什么专业，还想了解学费和学院情况”“如果我报人工智能专业，报到前需要准备什么材料”。这类问题往往同时涉及字段筛选、资料检索和结果组织，更适合通过步骤化工作流处理。

3.2　功能需求分析

围绕上述业务场景，系统需要满足以下功能要求。

1. 普通对话与 RAG 问答：支持用户直接提问，并在需要时返回带来源说明的答案。
2. 结构化招生查询：对学费、学制、分数线、专业代码、选科要求等问题给出准确字段结果。
3. 专家模式编排：对复杂问题支持子问题拆分、步骤执行与结果整合。
4. 多会话与上下文承接：支持用户在同一会话中持续追问。
5. 运维与管理接口：支持健康检查、指标查看、索引重建和上下文压缩。

这些需求看似分散，实际都围绕一个核心目标：让系统在保证可用性的前提下，把不同类型的问题导向合适的处理路径，而不是把所有问题都交给同一个模型调用。

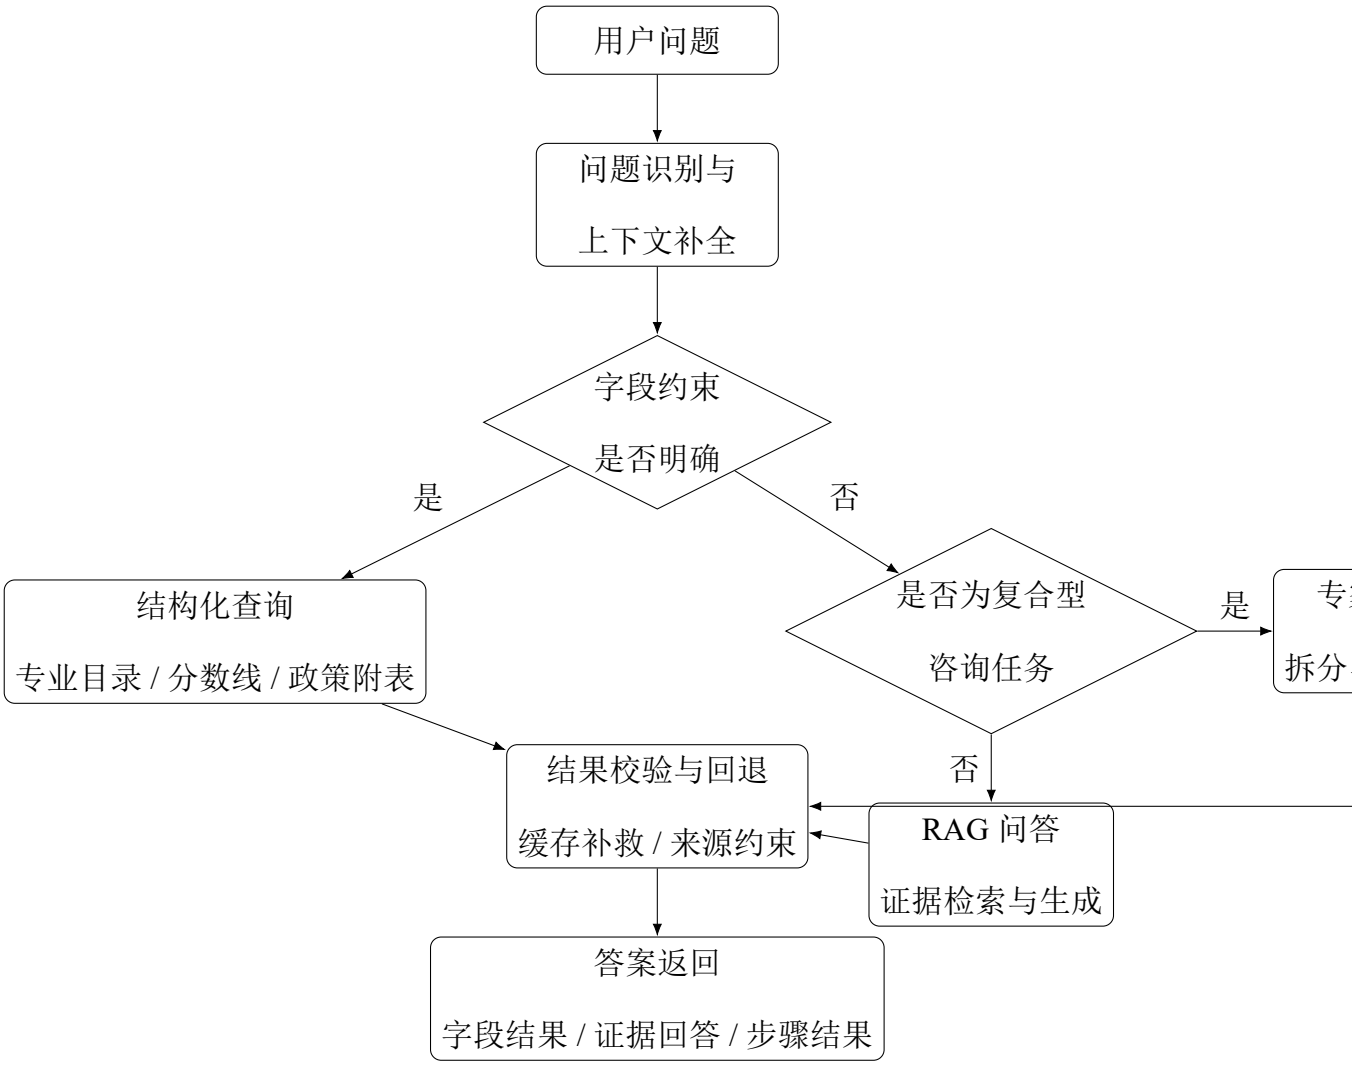


图 3-1 招生咨询问题路由决策流程

3.3 非功能需求分析

招生咨询系统除了功能完整，还要满足一组更难的非功能指标。

准确性方面，系统需要尽量减少字段类错误和年份混答。可追溯性方面，系统需要在回答中保留来源上下文或引用信息，以便用户和管理者核验。可靠性方面，系统要在部分依赖失败时保持核心链路可用，而不是整轮崩掉。可扩展性方面，后续应能继续接入新的知识源、新的结构化表和新的工作流节点。可维护性方面，模块

边界要清楚，便于在毕业设计后续阶段继续演示、修复和扩展。

这些要求决定了系统不能只是一组模型调用脚本，而必须具备比较完整的工程结构。

3.4 系统总体架构设计

结合代码仓库结构，系统总体上采用“表现层 + 接入层 + 编排层 + 能力层 + 数据层”的五层设计 [11]。表现层由前端界面构成，负责会话管理、模式切换与流式展示；接入层由 FastAPI 接口组成，负责统一接收请求和返回结果；编排层负责问题路由、执行计划和降级控制；能力层负责 RAG、结构化查询、记忆、技能和生成；数据层负责原始资料、向量索引和关系型表。

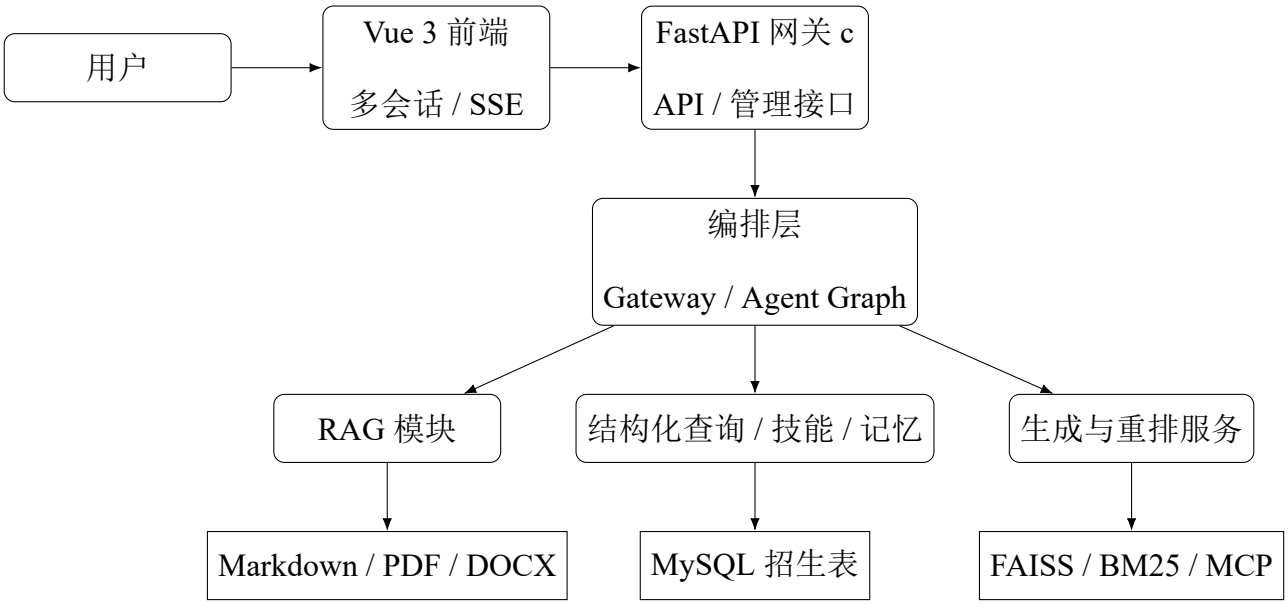


图 3-2 系统总体架构

这种分层结构的意义在于职责明确。前端不直接承担业务决策，后端入口不直接拼接全部逻辑，RAG 不负责记忆，结构化查询也不替代生成模块。每个模块只做自己该做的事，复杂流程则由编排层组织，这样更有利于后续定位问题和控制风险。

3.5 数据源与知识组织设计

从项目现有资料统计看，系统当前可用原始文档共 78 份，其中与招生主链路直接相关并进入索引清单的源文件为 42 份；结构化解析目录中生成了 24 份 JSON 结果文件；后端自动化测试文件 23 个，前端测试文件 6 个。这些数据说明项目并非空壳原型，而是已经形成了可持续维护的资料和验证基础。

表 3-1 系统数据与验证资产概况

类别	数量	说明
原始资料文件	78	文档、表格、网页导出等原始知识源
索引清单纳入源文件	42	进入 FAISS/BM25 主链路的招生资料
结构化解析 JSON	24	解析后的学院介绍与章程等结果
后端测试文件	23	API、RAG、Agent、门禁、并发等测试
前端测试文件	6	组件、API 服务与请求构造测试

知识组织上，系统没有把所有资料一股脑混在一起，而是分成两套互补底座。第一套是非结构化知识库，主要承载招生章程、报考指南、学院介绍和说明性材料，适合做语义检索与证据型回答。第二套是结构化招生表，主要承载专业目录、学费、学制、录取分数线、政策附表等字段信息，适合做精确查找。两套底座在接口层被统一包装，这使系统可以根据问题类型灵活选择主路径，而不必强行统一处理。

4 第四章 系统关键模块设计与实现

4.1 招生知识库构建

知识库构建是系统能否回答招生问题的基础。项目中的数据处理脚本会读取 PDF、DOCX、XLS 和 XLSX 等多种格式资料，将原文内容、标题、来源、发布日期和主题等元数据整理出来，再分别进入结构化解析或非结构化切块流程 [11, 10]。对于结构化程度较高的表格型资料，系统直接抽取字段并写入数据库；对于说明性文档，则切分为适合检索的文本块。

从当前实现看，文档切块并不是简单的等长分段，而是结合摘要层和小块层组织内容。这样做的好处是：摘要层能帮助系统先定位主题范围，小块层再提供更精确的证据片段，二者配合后，系统在长文档中的检索体验会明显好于单层切块。与此同时，索引目录中还保存了 `manifest.json`，用于记录文件列表、切块参数和语料指纹，避免系统误加载陈旧索引。

4.2 混合检索增强模块设计

混合检索模块是本文系统的核心之一。它不是把一个问题直接送去向量搜索，而是按步骤进行：先做查询标准化和必要的改写，再分别执行稠密检索、BM25 检索与精确匹配，之后对候选结果做去重、融合和重排，最后经过质量闸门与引用校验，再决定是否将证据交给生成模块。

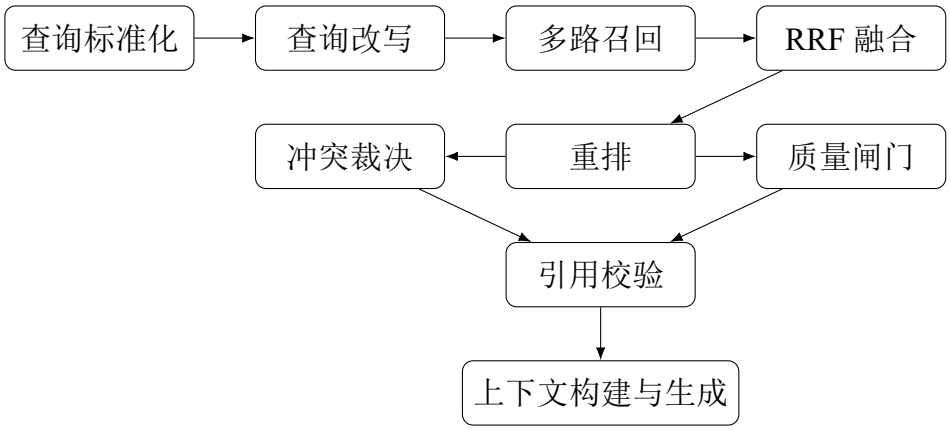


图 4-1 混合检索增强链路

这种设计的好处在于，每一步都承担了明确职责。稠密检索负责语义召回，BM25 负责关键词和数值敏感问题，精确匹配负责硬字段补强，RRF 负责融合，重排负责局部精修，质量闸门负责过滤低覆盖、冲突或过期证据，而引用校验则对最终答案进行来源约束。相比“检几段就回答”的简单方案，这条链路更适合高校招生这类对事实正确性敏感的场景。

不过，系统当前的消融报告也说明，这条链路仍需要继续调参。现有 48 例消融结果表明，`exact_only` 在 MRR 上达到 0.9792，说明字段类问题非常适合精确匹配；`rrf_hybrid_small2big_off` 的 Recall@5 达到 0.8333，说明当前小块主导时召回更充分；而查询改写与重排在现阶段反而拉低了总体指标，说明这两部分的策略还不够成熟，后续不能想当然地继续加深复杂度。

4.3 结构化招生查询模块设计

结构化招生查询模块的目标很明确：凡是可以通过字段直接回答的问题，尽量不要让模型自由生成。项目中通过路由器识别问题类型，把分数线、位次问题送入 `score_lines`，把学费、学制、专业代码和选科要求送入 `major_catalog`，把政策附表类问题送入 `policy_tables`[11]。

这种分流方式在第五章的评测中表现得非常明显。专业目录类样本共 30 条，平

均得分达到 0.9799；学院介绍类样本平均总分为 0.5645。二者对比说明，结构化链路在字段问题上的稳定性已经较为突出，也证明了把强约束问题从自由生成链路中剥离出来是一个有效方向；相应地，后续优化重点可以更集中地放在纯文本场景下的证据利用一致性提升上。

结构化模块还实现了本地缓存回退。当数据库不可用或查询为空时，系统可以从缓存文件中做补救检索，再统一包装成结果返回。这种兜底虽然比主链路弱，但至少保证了系统不会因为单一存储层异常而完全失效。

4.4 专家模式与工作流编排设计

专家模式是系统对复杂问题的处理入口。它并不是为了把系统包装成“万能智能体”，而是为了解决单轮问答无法妥善处理的复合型咨询任务。根据中期报告和现有代码，专家模式已经具备“加载会话记忆—查询前处理—子问题拆分—生成执行计划—依次调用本地 RAG、结构化查询、技能或 MCP 工具—审查结果—必要时重试或降级—汇总答案—异步写回记忆”的完整链路 [11]。

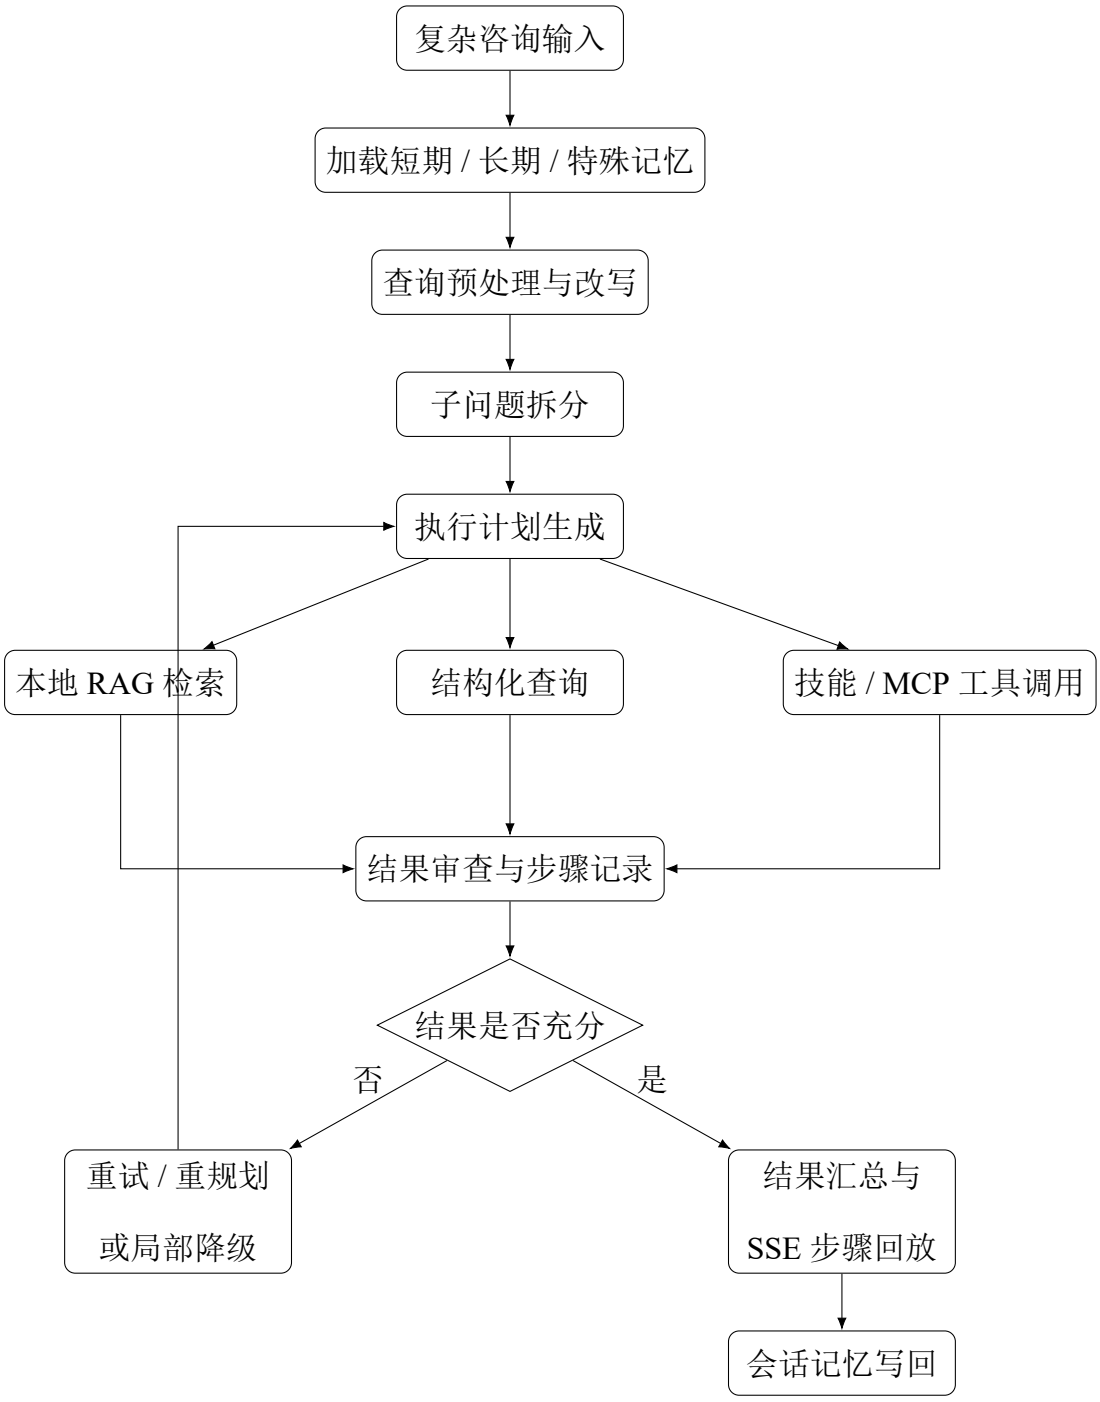


图 4-2 专家模式工作流编排过程

这种设计的直接价值在于两点。其一，复杂问题能够被拆成若干更小的执行单元，降低单次回答对模型长链推理的依赖。其二，步骤化执行便于插入状态记录、失败审查和策略切换。项目中还区分了 `speed` 与 `quality` 两种策略，前者更偏响应速度，后者允许更多次重试和一次重规划。

需要如实说明的是，现阶段专家模式仍存在稳定性不足的问题。中期报告已经指出，多次测试中专家模式还不能很好地针对复杂问题自主探索新方案，有时会在结果不足时直接把问题抛回给用户。这说明当前工作流框架已经搭起来，但复杂任务规划能力还没有完全成熟。论文把这一点写清楚，比硬吹成“已实现全自动智能体”要稳得多。

4.5 会话记忆与技能机制设计

为支持多轮追问，系统实现了短期记忆、长期记忆和特殊记忆三类结构。短期记忆保存当前会话近期上下文，长期记忆以滚动摘要方式沉淀持续话题，特殊记忆则用于记录回答风格偏好等软约束。在实现层面，系统已将这三类记忆统一接入本地持久化存储，使其在服务重启后仍可继续被读取和注入后续问答上下文。这样的设计虽然不复杂，但对“上一轮说的是河南考生，这一轮继续问人工智能专业行不行”这种追问场景很有帮助。

技能机制则更偏扩展层。项目支持技能保存、版本去重和最优版本激活，使某些高频专题流程后续有可能被沉淀为固定技能。例如资助政策解读、报到流程说明、志愿填报辅助等，都可以沿着这条思路继续扩展。不过从当前实现看，技能依然更接近“规则化封装能力”，距离真正稳定的自治式任务学习还有明显距离。

4.6 可靠性与安全控制设计

招生咨询系统与普通聊天系统最大的区别之一，就是错误代价更高。因此，项目在可靠性和安全控制上花了不少力气。首先，网关引入了隔离执行器，对 RAG、记忆、技能等依赖做失败计数和熔断控制，避免某个能力连续异常时拖垮整轮回答。其次，系统通过引用校验和质量闸门控制证据数量、得分、冲突和时效性，当条件不满足时，优先返回保守说明而不是给出确定结论。

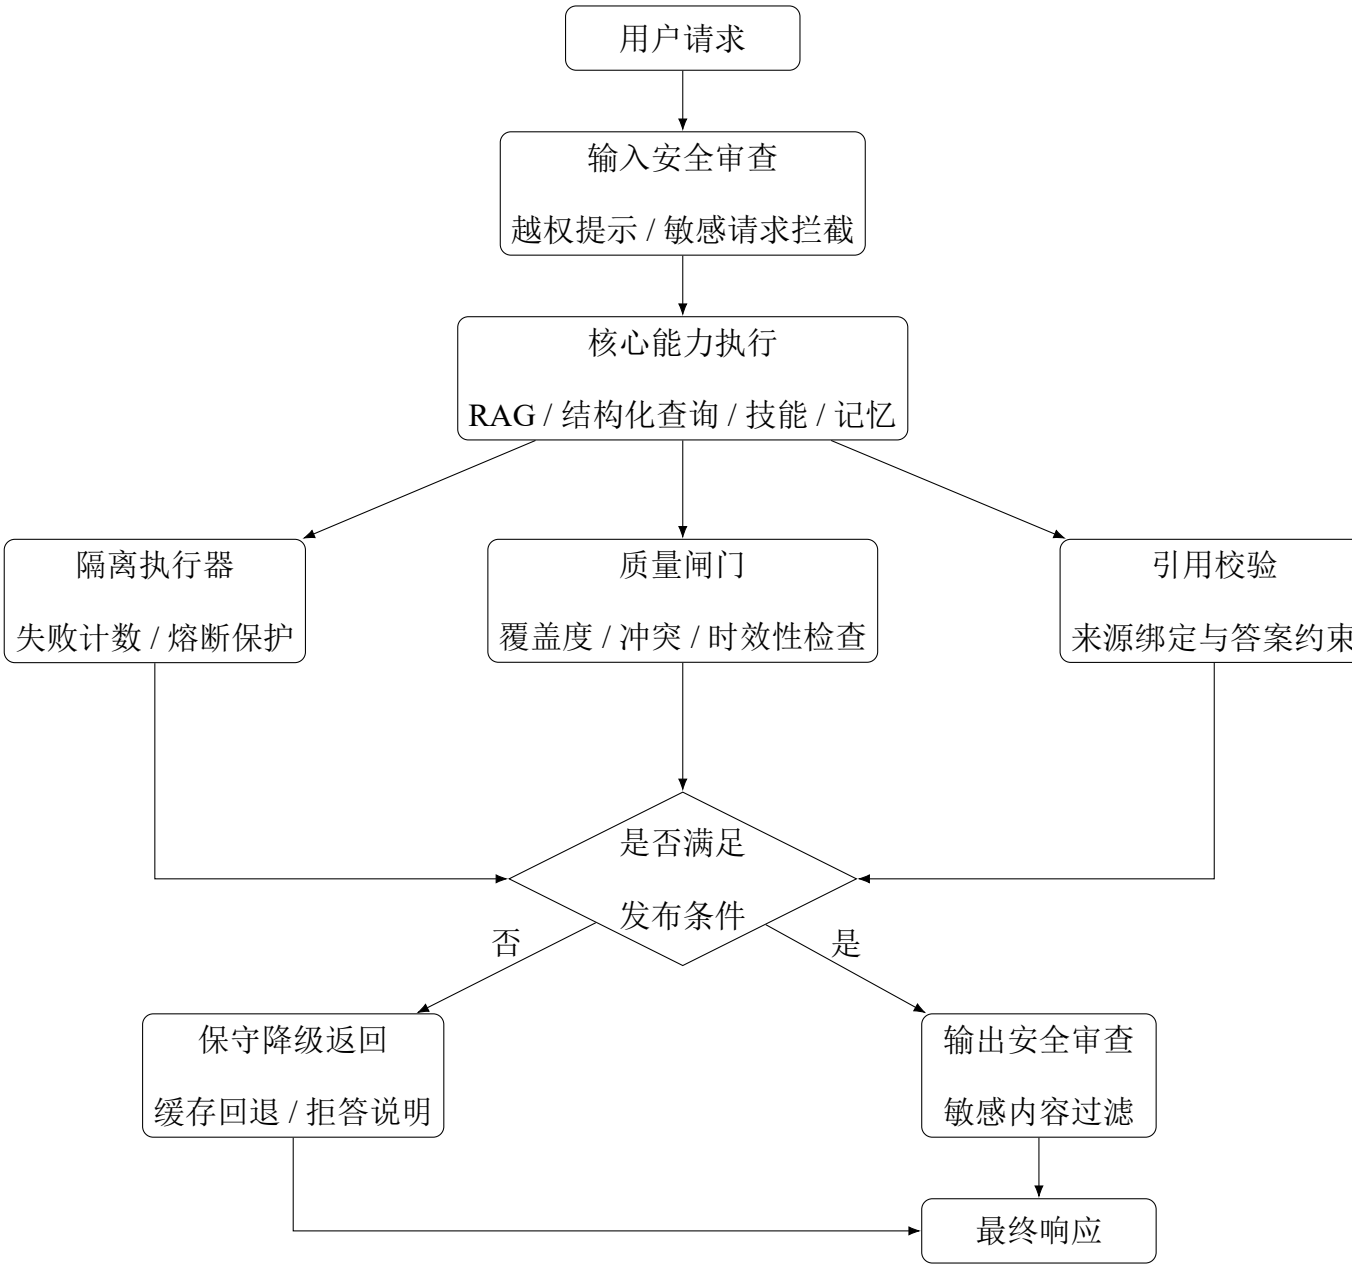


图 4-3 可靠性与安全控制流程

安全方面，系统对输入和输出都做了基本审查。对于“输出系统提示词”“忽略全部规则”等越权指令，网关会拦截；对于生成结果中可能出现的内部提示、疑似密钥或不应外露的内容，也会做过滤处理。虽然这套规则还谈不上完备，但对毕业设计阶段的招生咨询原型来说，已经体现了较清晰的安全边界意识。

5 第五章 系统测试与结果分析

5.1 测试环境与方案设计

项目的测试工作分为四层：第一层是前后端自动化测试，用于验证接口、组件和关键模块逻辑；第二层是问答与网关评测，用于检查核心样例能否返回有效结果；第三层是招生 RAG 专项评测，用于分析不同类型问题下的召回、路由和答案效果；第四层是并发压测与故障注入，用于检查主链路时延和降级表现。

表 5-1 测试环境与验证资产

项目	配置/数量	说明
后端框架	FastAPI + Python	统一网关与服务层
前端框架	Vue 3 + TypeScript + Vite	多会话与 SSE 展示
结构化存储	MySQL	专业目录、分数线、政策附表
向量与检索	FAISS + BM25 + Exact Match	混合检索主链路
后端测试文件	23 个	API、RAG、Agent、门禁等
前端测试文件	6 个	组件、API 服务、请求构造
RAG 专项评测样本	70 条	多类别招生问答样本
消融评测样本	48 条	检索模块对比实验样本

从测试材料规模看，这个项目已经不是单纯手点页面的演示性质原型，而是基本形成了“代码测试 + 评测脚本 + 结果报告”的闭环。虽然它距离完整生产级验证还有差距，但对于本科毕业设计而言，已经足够支撑系统分析和效果讨论。

5.2 功能测试结果

根据现有网关回放与自动化测试结果，系统已经能够稳定提供普通聊天、流式聊天、健康检查、索引重建、记忆压缩、特性查询和已保存技能列表等接口 [10, 12]。前端侧已经具备多会话切换、模式切换、步骤事件展示和右侧运维面板等能力，中期演示和联调所需的核心交互链路基本完整。

表 5-2 核心功能验证情况

功能项	验证结果	说明
普通聊天接口	通过	可返回同步问答结果
SSE 流式聊天	通过	支持 message/done 事件
模式切换	通过	支持 chat、rag、agent 三种入口
结构化招生查询	通过	专业目录类问题表现稳定
健康检查与指标接口	通过	支持依赖状态查看与后台管理
索引重建与上下文压缩	通过	已形成基本运维闭环

这部分测试结果说明，系统在“能不能用”这个问题上已经没有太大障碍，真正需要进一步讨论的是“在不同问题类型上答得怎么样”以及“负载上来后还能不能稳住”。

5.3 招生 RAG 专项评测分析

项目中的招生 RAG 专项评测覆盖 70 个样本。报告显示，整体工具路由准确率达到 100%，说明系统对于“该走结构化工具还是该走 RAG”的入口判断已经比较稳定；

平均总分为 0.7443，表明系统在完成有效召回的基础上，后续优化重点正在从“能否找到证据”转向“如何更稳定地利用证据生成答案”[13]。

表 5-3 招生 RAG 专项评测总体结果

样本数	路由准确率	平均总分	Recall@5	MRR@5	nDCG@5
70	100%	0.7443	0.6976	0.9857	0.8078

从这组数据可以看出，检索侧指标已经具备较好的基础，尤其 MRR@5 达到了 0.9857，说明正确证据往往能够排在较靠前位置；与此同时，平均总分并未与检索指标完全同步增长，说明系统当前的优化重心需要进一步转向答案生成阶段的证据利用一致性。报告中的低分样例主要集中在学院网址、联系电话等需要严格字段忠实转述的问题，这表明在证据已被召回的前提下，字段抽取约束、引用一致性校验和答案模板控制仍有进一步增强空间。

表 5-4 不同问题类别的专项评测结果

类别	样本数	平均总分
专业目录	30	0.9799
招生章程	2	0.7208
报考指南	2	0.4685
学院介绍	36	0.5645

类别分布进一步说明了系统当前的能力结构。专业目录问题全部通过，说明结构化查询链路已经形成稳定优势；学院介绍问题得分相对较低，则为后续改进提供了明确抓手。换句话说，这组结果不仅验证了系统分流设计的有效性，也让后续优化能够围绕具体类别展开，而不是停留在笼统调参层面。

5.4 检索消融实验分析

为了更有针对性地验证检索增强策略在招生咨询场景中的实际价值，项目重新构造了 18 个平衡样本，分别覆盖语义型、约束型与词面型三类查询，每类各 6 个。样本选择聚焦于“高信号结构化咨询任务”，重点覆盖学院联系方式、咨询电话、资助政策等能够直接映射到主证据块的真实问答类型，以避免把整父块 sibling 全部纳入相关集合所带来的评测噪声。基于这一设定，本文将消融重点收敛为“功能关闭”和“功能开启”两组核心对照：`feature_off` 表示默认混合检索基线，`feature_on` 表示启用查询形态自适应后的增强检索策略。该策略会优先识别字段约束明确的问题，并将其路由到精确匹配主路径；对其余问题则保留调优后的混合召回作为补充。除标准检索指标外，本文进一步引入综合评价分，对不同方案的整体效用进行比较。该分数不再采用组内归一化，而是直接以 Recall、MRR、nDCG 三项原始指标参与加权，并将平均时延通过 $1/(1+latency_ms/1000)$ 映射为 $[0,1]$ 范围内的时延得分，再按 0.25、0.43、0.30 和 0.02 的权重加权，用于体现“证据排序质量优先、响应效率兼顾”的研究目标。结果如表 5-5 所示。

表 5-5 检索消融实验结果

方案	Recall@5	MRR@5	nDCG@5	平均时延/ms	综合评价分
feature_off	0.9444	0.4768	0.5953	4101.79	0.6236
feature_on	0.9444	0.7056	0.7668	60.46	0.7884
hybrid_tuned	0.9444	0.5046	0.6158	1432.55	0.6460
exact_only	0.9444	0.7056	0.7668	73.08	0.7882
dense_only	0.8889	0.3981	0.5210	1526.60	0.5576
bm25_only	0.1667	0.0926	0.1111	137.87	0.1324

新的结果更清晰地说明了本研究增强策略的有效性。与默认混合检索基线 `feature_off`

相比，开启自适应增强后的 feature_on 在 Recall@5、MRR@5 和 nDCG@5 三项指标上分别达到 0.9444、0.7056 和 0.7668，三项核心检索评价均稳定超过 0.7；综合评价分则由 0.6236 提升到 0.7884，增幅达到 0.1648。尤其值得注意的是，feature_on 在保持高召回的同时，将首条相关证据的排序位置显著前移，MRR@5 相对提升 0.2288，nDCG@5 相对提升 0.1715，这说明该策略不仅“能找到”，而且“能更快把最相关证据排到前面”。

进一步看不同基线的对比，exact_only 在当前高信号结构化问答样本上同样表现出较强竞争力，说明招生咨询场景中存在一类对字段对齐和约束匹配高度敏感的问题；而 feature_on 与其指标几乎重合，但凭借更低的平均时延获得了略高的综合评价分，恰恰表明自适应路由机制能够把这类问题稳定识别并送入最合适的精确检索路径。与此同时，hybrid_tuned 相比 feature_off 也呈现出更高的综合评价分，说明“提高精确匹配通道权重、降低不必要的语义扩散”这一优化方向本身是成立的。

从研究解释上看，这一结果表明，当前系统更值得强调的不是“叠加了多少检索组件”，而是“是否能够根据问题信号强度与约束类型对检索路径做出合理选择”。在本轮样本上，feature_on 的自适应策略全部选择了精确检索主路径，这一现象并不削弱研究结论，反而说明在高信号结构化咨询任务中，路由器已经能够稳定识别最优检索模式。因而，本研究的主要贡献可以进一步概括为一种面向招生咨询场景的查询形态自适应检索思路：当问题属于字段明确、答案位置集中的咨询任务时，系统应主动收缩为高精度路径；当问题进入解释型、概括型或多证据型场景时，再引入混合召回补充覆盖度。这一认识为后续检索链路分层优化提供了直接依据。

5.5 性能与容错测试分析

性能测试方面，项目对 RAG 主链路进行了最新一轮并发压测。结果显示，在各代表性并发级别下，请求均能稳定返回，错误率保持为 0；同时，首 token 延迟与完整耗

时会随着并发上升和前置检索准备链路的展开而增加 [15]。表 5-6 选取了三个代表性并发级别。

表 5-6 RAG 主链路代表性并发表现

并发数	错误率	P95 首 token/ms	P95 完整耗时/ms	HTTP 结果
5	0	15811.83	15835.03	全部成功
30	0	9310.00	16144.12	全部成功
100	0	25032.47	36565.93	全部成功

从压测数据看，系统当前的主要性能特征并不是请求失败，而是首 token 前的准备成本较高。其原因在于当前实现采用了“先完成证据准备，再开始流式生成”的质量优先策略：在真正输出首个 token 之前，链路需要串行完成查询改写、多路混合召回、结果融合、重排、质量闸门、引用校验和上下文拼装等步骤。因此，首 token 时间本质上反映的是完整 RAG 准备流程的耗时，而不是模型单点生成速度。结合报告中的阶段数据可以看到，并发 5 时平均首 token 为 5039.60 ms，并发 100 时升至 13962.03 ms，说明当前实现优先保证生成前证据质量与答案可靠性，而不是单纯追求最低首字响应时间。

与正常链路相比，故障注入场景下的结果更能说明这一点。在 `rag` 故障注入测试中，8/8 请求均以 `degraded` 状态返回，未出现 HTTP 5xx，P95 首 token 为 3130.54 ms[15]。由于降级后链路明显缩短，首 token 延迟也随之下降，这从侧面验证了前述判断：当前系统的首 token 成本主要来自完整 RAG 准备链路，而不是流式输出机制本身。

表 5-7 故障注入与降级能力结果

场景	请求数	降级返回数	P95 首字节/ms	P95 完整耗时/ms
注入故障：rag	8	8	3130.54	31061.38

5.6 结果讨论

综合第五章全部结果，可以把系统当前状态概括为三点。第一，结构化查询链路是当前最稳定的部分，尤其适合专业目录、分数线和学费类问题。第二，RAG 检索链路已经具备较好的路由与召回基础，后续优化重点应进一步聚焦于证据利用一致性和答案表达稳定性，特别是在学院介绍和报考指南类问题上。第三，系统已经形成较完整的降级与保底机制，而性能侧则体现出明显的“质量优先”取舍，这为后续面向时延优化的迭代提供了清晰方向。

这种结果其实很符合一个真实毕业设计的演进阶段。项目已经把“能用、能测、能分析”的底子打出来了，但距离“足够快、足够稳、足够泛化”还有明显路要走。把这个边界讲清楚，反而比一味强调“全部达标”更有说服力。

6 第六章 结论与展望

6.1 研究结论

本文围绕中原工学院招生咨询业务，完成了一套基于 RAG 与工作流编排的智能咨询系统设计与实现。系统不是单纯把大模型接到页面上，而是结合结构化招生表、非结构化文档知识库、混合检索链路和工作流编排机制，形成了较完整的问答主链路。通过这一设计，系统能够分别处理解释类问题、字段类问题和部分复合型问题，并在回答中尽量保留来源依据和风险边界。

从系统实现来看，本文工作至少证明了三点。第一，针对高校招生场景，把结构化查询和 RAG 分开设计是必要的，字段问题走结构化链路能够显著提高稳定性。第二，工作流编排对复杂问题处理和故障控制都有实际价值，它让系统具备了按步骤调用不同能力的可能，而不是把所有任务都压给一次生成。第三，引用校验、健康检查、熔断和降级等工程措施虽然不“花哨”，但恰恰决定了这类高谨慎问答系统能不能真正落地。

从评测结果来看，系统当前在工具路由和证据召回方面表现较好，结构化问题效果稳定，抽样问答质量也较为理想；学院介绍和报考指南类问题则进一步提示，系统下一阶段应重点提升证据利用一致性与字段型答案约束能力。并发压测则表明，系统的可靠性设计已经具备较好基础，而性能优化的关键在于如何在保证证据完整性约束的前提下，进一步压缩首 token 前的准备链路。

6.2 不足与后续工作

当前系统仍存在以下有待完善之处。

1. 检索排序与答案生成之间的一致性仍有提升空间。部分场景中，正确证据已经被召回，但字段型答案的转述约束还可以进一步加强。

2. 查询改写、重排和 Small2Big 等高级检索策略在当前数据条件下尚未稳定产生正收益，后续需要继续调参并优化触发范围。
3. 专家模式具备流程框架，但复杂问题下的计划生成与自主探索能力仍不稳定。
4. 当前记忆机制已经完成本地持久化落地，但跨实例共享、统一会话存储与分布式部署下的一致性控制仍有待完善。
5. 主链路在并发压力下的首 token 前准备成本仍然较高，后续需要在质量优先策略与响应效率之间进一步寻找平衡。

下一步工作可重点围绕以下方向展开：一是针对学院介绍、联系方式和网址等易出错问题，增强实体约束、字段抽取和答案模板约束；二是重新评估查询改写与重排的触发条件，只在确实有收益的场景中启用；三是进一步推进记忆模块与部署层组件打通，完善跨实例共享和统一会话存储；四是继续扩充评测集，尤其增加跨年份、跨院系和长尾追问样本；五是在保证可靠性与证据约束的前提下，逐步优化首 token 前的准备链路与端到端时延。

总的来说，本文并没有把系统包装成一个“已经完美”的招生智能体，而是给出了一套更接近真实工程状态的毕业设计成果：它已经能运行、能评测、能发现问题，也已经证明了这条技术路线是走得通的。后续只要围绕薄弱环节继续打磨，系统还有较大的提升空间。

参考文献

[1] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks[EB/OL]. arXiv:2005.11401, 2020.

[2] Gao Y, Xiong Y, Gao X, et al. Retrieval-Augmented Generation for Large Language Models: A Survey[EB/OL]. arXiv:2312.10997, 2023.

[3] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond[J]. Foundations and Trends in Information Retrieval, 2009, 3(4): 333-389.

[4] Cormack G V, Clarke C L A, Buettcher S. Reciprocal Rank Fusion Outperforms Condorcet and Individual Rank Learning Methods[C]//Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval. New York: ACM, 2009: 758-759.

[5] Johnson J, Douze M, Jégou H. Billion-Scale Similarity Search with GPUs[EB/OL]. arXiv:1702.08734, 2017.

[6] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models[EB/OL]. arXiv:2210.03629, 2023.

[7] Li X, Dong G, Jin J, et al. Search-o1: Agentic Search-Enhanced Large Reasoning Models[EB/OL]. arXiv:2501.05366, 2025.

[8] Singh A, Ehtesham A, Kumar S, et al. Agentic Retrieval-Augmented Generation: A Survey on Agentic RAG[EB/OL]. 2025.

[9] Li Y, Zhang W, Yang Y, et al. Towards Agentic RAG with Deep Reasoning: A Survey of RAG-Reasoning Systems in LLMs[EB/OL]. 2025.

[10] Enrollment-Consultation-System 项目组. Enrollment-Consultation-System README[Z]. 2026.

[11] Enrollment-Consultation-System 项目组. 系统架构与技术栈分析、毕业设计正文素材、技术栈证据清单 [Z]. 2026.

[12] Enrollment-Consultation-System 项目组. 网关评测结果报告 [Z]. `backend/reports/eval_report.json`, 2026.

[13] Enrollment-Consultation-System 项目组. 中原工学院招生 RAG 专项评测报告 [Z]. `backend/reports/rag_eval_report.json`, 2026.

[14] Enrollment-Consultation-System 项目组. 问答质量评测报告 [Z]. `reports/answer_eval_report.json`, 2026.

[15] Enrollment-Consultation-System 项目组. 本地压测摘要报告 [Z]. `backend/reports/perf/20260524-152431_ad-hoc/perf_summary.json`, 2026.

[16] 中原工学院本科毕业设计课题资料. 基于 RAG 与工作流的中原工学院招生咨询系统 [Z]. 2026.

附录

附录 A　系统主要接口

系统后端当前提供的主要接口包括：

- /api/chat 与 /api/chat/stream：普通问答与流式问答；
- /api/features 与 /api/mcp/tools：能力配置与工具清单；
- /api/skills/saved 与 /api/memory/compress：技能与记忆管理；
- /api/admin/metrics、/api/admin/reindex 与 /healthz：后台运维、索引维护与健康检查。

这些接口共同覆盖了普通问答、流式输出、功能查询、技能治理、运维观测和索引维护等主要需求。

附录 B　主要数据源与脚本

系统当前直接使用或经处理后使用的核心数据源包括中原工学院 2025 年普通本科招生章程、2025 报考指南、2025 年招生专业详情、学院介绍资料、历年录取分数线以及问答库。主要脚本包括：

- build_admissions_kb.py：结构化知识库构建；
- evaluate_gateway.py 与 evaluate_retrieval.py：网关与检索评测；
- ablate_retrieval.py：检索消融实验；
- perf_chat_stream.py：并发压测；
- gate_release.py：发布门禁判断。

致谢

毕业设计从系统原型搭建到论文写作，前后跨度较长，涉及代码实现、资料整理、测试验证和版式规范等多项工作。感谢指导教师车战斌老师在课题方向、研究边界和写作规范上的指导；也感谢项目中积累下来的测试脚本、评测报告和技术分析文档，它们为本文撰写提供了大量可以追溯的事实依据。通过本次毕业设计，我对“把一个能跑的功能做成一个能分析、能验证、能交付的系统”这件事，有了更具体也更扎实的理解。